

1-1. 프로젝트 개요

1-1-1. 프로젝트 주제

본 프로젝트는 Hand Bone X-ray 이미지를 활용하여 뼈 영역을 정밀하게 분할하는 Bone Segmentation 모델 개발을 목표로 한다. 이를 통해 골절 진단, 수술 계획 수립, 맞춤형 의료 장비 제작 등 의료 현장에서의 진단 정확도와 업무 효율성 향상에 기여하고자 한다.

1-1-2. 프로젝트 구현 내용, 컨셉

1-1-2-1. 프로젝트 구현 내용

Hand Bone X-ray 객체가 포함된 이미지를 입력으로 받아 모델은 29개 클래스 각각에 대한 확률 맵을 출력하는 멀티채널 예측을 수행하며, 클래스별 확률 맵에 threshold를 적용하여 임계값을 초과하는 모든 클래스를 해당 픽셀에 할당한다.

각 모델에 Augmentation, loss, scheduler 등의 실험을 단계적으로 진행하였고 최종 앙상블에 사용한 모델들의 실험 단계별 성능 변화는 다음과 같다. 성능은 Leader Board Score 기준으로 작성되었다.

	UperNet	HRNet	SwinUnet
Base	0.9487	0.9642	0.9447
Encoder	0.9493	-	-
Augmentation	0.9545	0.9706	0.9575
Loss	0.9557	0.9709	0.9545
Scheduler	0.9561	0.9709	-
Resize	0.9743	-	-
TTA	0.9745	0.9753	-
Ensemble	0.9758		

1-1-2-2. 프로젝트 평가 지표: Dice score

Dice score는 이미지 분할에서 예측 영역과 정답 영역 간의 중첩 정도를 측정하는 대표적인 평가지표이다. 정답 마스크 (Ground Truth)와 모델 예측 마스크(Prediction)의 겹침 정도를 0~1 사이의 값으로 나타내며, 값이 1에 가까울수록 예측이 정답과 거의 일치함을 의미한다. Segmentation 문제에서는 픽셀 단위로 다음과 같이 계산된다.

$$\text{Dice} = \frac{2 \times TP}{2 \times TP + FP + FN}$$

- TP(True Positive)는 정답과 예측이 모두 1인 픽셀
- FP(False Positive)는 예측은 1이나 정답은 0인 픽셀
- FN(False Negative)는 정답은 1이나 예측은 0인 픽셀

1-1-3. 활용 장비 및 재료(개발 환경, 협업 tool 등)

본 프로젝트에서는 서버당 NVIDIA V100 GPU 1개가 장착된 환경을 총 3대 활용하였다. 개발 언어는 Python 3.10을 사용하였으며, 전체 실험은 원격 서버 환경에서 수행되었다. 소프트웨어 환경은 Linux 기반이며, VS Code를 통해 서버에 접속하여 개발 및 실험을 진행하였다.

협업 도구로는 Notion을 활용한 문서 공유 및 일정 관리, Git을 통한 형상 관리, Slack을 이용한 팀 내 커뮤니케이션을 사용하였다.


1-1-4. 프로젝트 구조 및 사용 데이터셋의 구조도

본 프로젝트는 EDA → 데이터 전처리 → 모델 학습 → 성능 개선 → 앙상블 → 결과 해석 및 시각화의 단계로 진행되었다. 학습에 사용된 데이터셋은 총 1,088명의 Hand Bone X-ray 이미지로 구성되어 있으며, 이 중 Train 데이터는 800명분, Test 데이터는 288명분이다. 양손을 촬영한 데이터이므로, 각 사람당 두 장의 이미지가 존재한다. 모든 이미지는 2048×2048 해상도로 동일하게 제공되었으며, 뼈 영역은 총 29개의 클래스로 구분된다. 다음은 예시 이미지이다.

1-2. 프로젝트 팀 구성 및 역할


- 박준영: EDA 및 모델 탐색
- 안태현: EDA, MMsegmentation library를 사용한 HRNet OCR 최적화
- 윤종욱: EDA, Data Split, SMP library를 사용한 U-Net++모델에 boundary feature decoder 구조 추가
- 이승현: swin unet 최적화
- 최정빈: baseline 결과 시각화, baseline code refactoring, SMP library를 사용한 UPerNet 최적화

1-3. 프로젝트 수행 절차 및 방법



데이터 전반에 걸쳐 반복적으로 나타나는 구조적 특성임을 확인하였다.

클래스별 분석 결과, overlap 비율은 finger 영역보다 carpal bone 영역에서 현저히 높게 나타났으며, 이는 손목 부위의 해부학적 구조가 밀집되고 복잡하기 때문으로 해석된다. 또한 겹치지는 않지만 경계를 공유하는 boundary-adjacent class pair 역시 finger-finger 및 carpal-carpal 조합에서 빈번하게 나타나, 본 segmentation task에서 경계 구분과 구조적 인접성이 주요 난이도 요소임을 시사한다.




1-4. 프로젝트 수행 결과

1-4-1. EDA

데이터 정합성 및 클래스 분포 분석



EDA의 첫 단계로 데이터의 기본적인 정합성과 신뢰성을 검토하였다. 모든 학습 이미지에서 29개 클래스가 누락 없이 존재함을 확인하였으며, 클래스별 픽셀 수 분포를 통해 데이터가 특정 샘플에 의해 편향되어 있지 않은지 분석하였다.

클래스별 픽셀 수에 대해 평균(mean)과 중앙값(median)을 함께 분석한 결과, 두 지표 간의 차이는 전반적으로 크지 않았다. 이를 통해 일부 극단적인 이상치에 의해 데이터 분포가 왜곡되지 않았음을 확인하였으며, 학습에 활용하기에 충분한 신뢰성을 갖춘 데이터셋임을 판단하였다.



Pixel-level Overlap 및 Boundary 특성 분석

Pixel-level 분석 결과, 일부 이미지에서 서로 다른 클래스가 동일한 픽셀을 공유하는 overlap 현상이 다수 관찰되었다. 이미지별 overlap 픽셀 수 분포를 확인한 결과, 이러한 현상은 특정 소수 샘플에서만 발생하는 annotation noise가 아니라




메타데이터 기반 난이도 요인 분석

앞선 분석을 통해 segmentation 난이도는 객체의 크기, 구조적 겹침, 경계 밀집도에 영향을 받는다는 점을 확인하였다. 이러한 난이도 요소를 validation split에 반영하기 위해, Test 데이터에도 동일하게 제공되는 메타데이터를 활용할 필요가 있다고 판단하였다.

본 분석에서는 성별 및 신장이 손의 크기와 관련이 있을 것이라는 가설을 설정하였다. 각 이미지의 손뼈 영역(mask)을 기반으로 총 뼈 픽셀 수를 계산한 결과, 성별에 따른 분포 차이가 관찰되었으며 신장과 손뼈 면적 사이에는 양의 상관관계가 확인되었다.

이는 신장이 손의 스케일을 간접적으로 반영하는 신뢰 가능한 proxy 변수임을 시사한다.



이러한 경향은 이후 validation split 설계에서 신장을 기준 변수로 선택하는 근거로 활용되었다.

1-4-2. Data Preprocessing & Data Split

1-4-2-1. Data Preprocessing

데이터 전처리를 위해 원본 이미지와 Ground Truth를 시각적으로 검토하였다. 그 결과, 반지를 착용한 이미지 1장과 팔에 보형물이 포함된 이미지 1장이 확인되었다. 해당 요소들은 테스트 데이터셋에 존재하지 않아 학습 시 noise로 작용할 가능성이 있다고 판단하여 제거하였다. 이때 ID 전체를 제거하지 않고 해당 이미지만 제거함으로써 데이터 손실을 최소화하였다.

또한 초기 학습 결과에 대한 worst-case 분석 과정에서 특정 ID에 속한 이미지에서 다수 클래스의 validation score가 0으로 나타나는 현상을 발견하였다. 육안 검토 결과 Ground Truth mask의 클래스 매칭 오류가 확인되어, 해당 mask에 대해 클래스 재매칭을 수행함으로써 데이터 정합성을 수정하였다.

1-4-2-2. Validation Split


설계 배경

Semantic segmentation 성능은 객체의 크기, 구조적 겹침,

경계 복잡도와 같은 요인에 크게 영향을 받는다. 그러나 overlap pixel이나 boundary-adjacent pixel과 같은 난이도 지표는 Ground Truth를 필요로 하므로 Test 데이터셋에는 직접 적용할 수 없다는 한계가 존재한다. 이에 따라 Test 데이터와 동일하게 제공되는 메타데이터를 활용하여 난이도를 간접적으로 반영하는 validation split 전략이 필요하다고 판단하였다.

Height 기반 Validation Split 설계


EDA 결과를 바탕으로 신장을 기준 변수로 선택하였다. Test 데이터의 신장 분포를 기준으로 3 개의 분위수 구간 h1, h2, h3 [154._165._173._186.]을 정의하고, 분위에서 벗어나는 구간은 h_out으로 관리하고 동일한 기준을 Train 데이터에 적용하여 validation set을 구성하였다.



Validation Fold 분포 검증

설계된 validation split이 Test 데이터셋의 특성을 충분히 대표하는지 확인하기 위해, Test 데이터와 각 validation fold 간의 신장 분포를 비교하였다. 그 결과, 모든 validation fold에서 신장 분포의 중앙값과 범위가 Test 데이터와 유사한 형태를 보였으며, 특정 fold에 신장 분포가 편중되지 않았음을 확인하였다.


이는 height 기반 split 전략이 Test 데이터의 메타데이터 분포를 안정적으로 반영하고 있으며, fold 간 데이터 불균형으로 인한 성능 편차가 발생할 가능성이 낮음을 시사한다.



난이도 지표 기반 Split 타당성 검증


앞서 설계한 validation split이 실제 segmentation 난이도를 균형 있게 반영하는지 추가 검증하였다. overlap pixel 수, boundary-adjacent pixel 수, 그리고 Radius와 Ulna를 제

외한 non-big bone pixel 분포를 fold별로 비교한 결과, 모든 fold에서 유사한 분포를 보였으며 특정 fold에 난이도가 편중되지 않았음을 확인하였다.



마지막으로, overlap pixel과 boundary-adjacent pixel 간의 관계가 단순히 손의 스케일 차이에 의해 발생한 현상인지 확인하기 위해, non-big bone pixel 규모에 따라 데이터를 구간화한 뒤 overlap-boundary 관계를 분석하였다. 그 결과, 손의 스케일을 통제된 이후에도 overlap과 boundary 간의 양의 상관관계가 각 구간에서 일관되게 유지됨을 확인하였다.

이는 overlap 및 boundary 특성이 단순한 크기 효과(scale effect)가 아니라, 손뼈 구조 자체에 기인한 난이도 요인임을 의미한다. 따라서 본 연구에서 정의한 난이도 기준은 스케일 변화에 강건하며, validation split 설계의 타당성을 추가적으로 뒷받침한다.



1-4-3. 모델 학습



1-4-3-1. baseline

모델 구조에 따른 성능 차이를 확인하기 위해, 다른 하이퍼 파라미터는 고정된 채 모델과 encoder만 변경하여 실험을 진행했다.

Model	Val Dice	LB Score
-------	----------	----------

FCN + ResNet50 (baseline)	0.9338	0.9313
DeepLabv3 + ResNet50	0.9418	0.9401
DeepLabv3 + ResNet101	0.9448	0.9384

그 결과 LeaderBoard Score가 가장 높은 DeepLabv3 + ResNet50을 새로운 baseline으로 선정하고, 해당 모델의 예측 결과를 분석하였다.




전체 Dice는 우세했으나 Overlap pixel과 Small pixel에 대한 예측 성능이 낮음을 확인하였다. 이를 개선하기 위해 입력 이미지의 resize 크기를 조절하는 실험을 진행하였다.

Resize	Model	Val Dice	LB Score
512×512 (baseline)	DeepLabv3 + ResNet50	0.9418	0.9401
1024×1024	DeepLabv3 + ResNet50	0.9664	0.9644
2048×2048	DeepLabv3 + MobileNetv3	0.9649	0.9602

2048×2048 해상도에서는 GPU 메모리 제약으로 작은 backbone을 사용했으며, 해상도가 증가할수록 성능이 향상되

는 경향을 확인하였다. 다만 실행 시간이 크게 증가함에 따라, 대부분의 실험은 512×512 해상도로 진행하고 최종 모델에 한해 고해상도 설정을 적용하여 비교하기로 하였다.



또한 baseline 모델의 Threshold 별 Dice를 확인한 결과, 기존 Threshold(=0.5)가 크게 문제되지 않음을 확인하였고, 클래스별 최적 Threshold가 다를 수 있음을 확인하였다. 이에 따라 최종 모델에서는 클래스별 best Threshold를 적용하기로 하였다.

다음은 baseline 모델의 하이퍼 파라미터이다.

하이퍼 파라미터	값
Model	DeepLabv3
Encoder	ResNet50
Pretrained Weight	ImageNet
Augmentation	Resize(512x512)
Loss	BCE
Learning Rate	0.0001 (Scheduler X)
Optimizer	Adam
Data split	Random Split
Random Seed	21
Threshold	0.5
Batch Size	8
Num Epochs	90
Val Every	3
Num Patience	5

1-4-3-2. SMP(Segmentation Model PyTorch) Models

구조화가 잘 되어 다양한 segmentation 모델과 backbone encoder를 손쉽게 적용할 수 있는 SMP(Segmentation Model PyTorch) 라이브러리를 활용하여 최적화를 진행하였다. architecture를 제외한 나머지 하이퍼 파라미터는 baseline과 동일하게 설정하였다.

Architecture	Val Loss (BCE)	Val Dice
DeepLabV3		0.9418

(baseline)		
Unet	0.00082565	0.94622
Unet++	0.00085098	0.9498
Manet	0.00081049	0.94623
DeepLabV3+	0.0008885	0.94669
UPerNet	0.00082656	0.95187
Segformer	0.00090654	0.9482

Validation Dice 기준 가장 성능이 우수한 UPerNet을 선택한 후 encoder 비교 실험을 진행하였다. Architecture가 CNN 기반 모델이므로, 공간적 국소 특징을 효과적으로 추출할 수 있는 CNN 계열 encoder를 중심으로 비교하였다. 또한, 전역 문맥 정보를 함께 활용할 수 있는 가능성을 확인하기 위해 Transformer 기반인 MiT encoder도 함께 고려하였다. 이 실험에서는 UPerNet으로 architecture를 고정하고 나머지 하이퍼 파라미터는 baseline과 동일하게 적용하였다. 다만 GPU 메모리 제약으로 EfficientNet-B6 encoder만 batch size 4로 실험하였다.

Encoder	Val Loss (BCE)	Val Dice
ResNet50 (baseline)	0.0012139	0.94603
ResNet101	0.0010611	0.94824
MIT-B2	0.0011542	0.94819
MIT-B3	0.0010497	0.94838
ResNeXt50_32×4d	0.0010295	0.94897
ResNeXt100_32×8d	0.0010857	0.94805
EfficientNet-B4	0.00099817	0.94874
EfficientNet-B5	0.0011921	0.94645
EfficientNet-B6	0.0011945	0.94452
SE-ResNet50	0.0010554	0.94821
SE-ResNet101	0.0010951	0.94436
SE-ResNeXt50_32×4d	0.0010776	0.94583
SE-ResNeXt101_32×4d	0.0010743	0.94481

Validation Dice 기준 가장 예측력이 높은 ResNeXt50_32×4d를 backbone encoder로 채택하고, augmentation 실험을 진행하였다. 우선 Contrast 증강을 적용하여 밝고 어두운 픽셀 간 차이를 강화함으로써 경계를 뚜렷하게 하여 예측 성능을 향상하고자 하였다. 대비를 강조하는 것이 목적이므로 밝기 변화는 적용하지 않았다.

Augmentation	Val Loss (BCE)	Val Dice
None (baseline)	0.00080806	0.95169
RandomBrightnessContrast	0.00078439	0.95188
CLAHE	0.00078053	0.95165

Validation Dice 기준 가장 예측력이 높은

RandomBrightnessContrast를 augmentation으로 채택하였다. 또한 train과 test 데이터 모두에서 손목이 포함된 샘플이 존재하므로, 모델이 이러한 경우에도 강건하게 예측할 수 있도록 Geometric 증강을 적용하였다.

Augmentation	Val Loss (BCE)	Val Dice
RandomBrightnessContrast (baseline)	0.00078439	0.95188
+ HorizontalFlip	0.00099483	0.95042
+Rotate	0.0010113	0.95037
+ Rotate + Translation	0.0007174	0.95671

Validation Dice 기준 가장 예측력이 높은 RandomBrightnessContrast + Rotate + Translation을 1차 최종 증강으로 채택하였다.

이후 overlap pixel과 small object에 대한 예측 성능을 향상하기 위해 Loss 실험을 진행하였다. 기본적인 균형 성능을 평가하기 위해 픽셀 단위 정확도와 전체 영역 일치도를 동시에 고려한 BCE + DICE Loss를 적용하였으며, DICE 외에 Jaccard 지표를 추가하여 작은 객체와 영역 중첩에 대한 민감도를 높이하고자 BCE + DICE + JACCARD Loss를 실험하였다. 또한 작은 객체와 클래스 불균형 문제를 보완하고 어려운 픽셀 학습을 강화하기 위해 DICE + FOCAL + TVERSKY Loss도 적용하였다.

Loss	Val Dice	LB Score
BCE (baseline)	0.95671	0.9545
BCE + DICE	0.9561	0.9552
BCE + DICE + JACCARD	0.95697	0.9557
DICE + FOCAL + TVERSKY	0.95656	0.9547

Validation Dice와 LB Score가 모두 가장 높은 BCE + DICE + JACCARD를 최종 Loss로 채택하였다. 이는 BCE와 DICE가 픽셀 단위 정확도와 전체 영역 일치도를 동시에 고려하고, Jaccard가 작은 객체와 영역 중첩에 대한 민감도를 보완해 균형 잡힌 학습을 가능하게 했기 때문이라고 판단했다. 또한, 전체 성능은 크게 증가하지 않았지만, Combined Loss를 사용하면 수렴 속도가 빨라지는 경향을 확인하였다.

Scheduler에 대한 실험을 진행하였다. ReduceLROnPlateau scheduler는 Validation Dice 기준으로 작동하므로, 하이퍼파라미터 val_every를 1로, num_patience를 10으로 조정하였다.

Scheduler	Val Dice	LB Score
None (baseline)	0.95667	0.9549
CosineAnnealingWarmupRestarts	0.95757	0.9561

ReduceLROnPlateau	0.95651	0.9554
CosineAnnealingLR	0.95699	0.9556

실험 결과 Validation Dice와 LB Score가 모두 가장 높은 CosineAnnealingWarmupRestarts를 최종 Scheduler로 선정하였다.

Optimizer	Val Dice	LB Score
Adam (baseline)	0.95757	0.9561
AdamW	0.95709	0.9555

추가로 optimizer로 Adam과 일반적으로 사용되는 AdamW를 비교하였다. 그 결과 AdamW는 오히려 성능이 하락하여 최종 optimizer로 Adam을 채택하였다. SGD도 실험하였으나 수렴 속도가 지나치게 느려 중간에 중단하였다.

전체적인 예측력은 많이 향상되었지만, 여전히 small pixel과 overlap pixel에 대한 예측력이 낮은 경향을 보여 이를 개선하기 위해 입력 이미지의 해상도를 확대하였다. 이 과정에서 GPU 메모리를 고려하여 batch size를 줄여 실험하였으며, 특히 2048×2048 해상도에서는 Mixed Precision Training을 적용하였다.

Resize	Batch Size	Val Dice	LB Score
512×512 (baseline)	8	0.95757	0.9561
1024×1024	4	0.97118	0.9705
2048×2048	2	0.97442	0.9739

모델의 입력 크기를 확대하자 뚜렷한 성능 향상을 확인하였으며, 이후 실험들은 2048×2048 resize와 batch size 2를 적용하여 진행하였다.

입력 크기가 변경됨에 따라 최적 augmentation도 달라질 것으로 판단하여, 추가적인 augmentation 실험을 수행하였다. 이를 통해 가장 성능이 좋게 나타난 augmentation을 최종 증강으로 선택하였다.

Augmentation	Val Dice	LB Score
1차 최종 증강	0.97442	0.9739
+ scale	0.97412	0.9739
+ scale + flip	0.97485	0.9743


지금까지 실험을 통해 도출한 하이퍼 파라미터를 적용하여 전체 데이터를 사용해 학습을 진행하였으나, validation set이 없어 오히려 성능이 불안정하게 나타났다.

Data	LB Score
80% Data	0.9743
Full Data (25epoch)	0.9521

Train 데이터에 다양한 증강을 적용했으므로, Test 데이터에서도 대비를 강화하거나 회전하는 방식으로 성능 향상을 기대하여 Test Time Augmentation(TTA) 실험을 진행하였다.

TTA	LB Score
None	0.9743
Flip + Contrast	0.9745

최종적으로 각 모델의 클래스별 최적 Threshold를 적용하여 LeaderBoard Score를 확인하였다.



Threshold	Val Dice	LB Score
0.5	0.97484	0.9745
클래스별 최적 Threshold	0.9752	0.9746

TTA와 클래스별 최적 Threshold를 적용함으로써 성능 향상을 확인하였으며, 해당 설정을 적용한 모델을 최종 모델로 도출하였다.

1-4-3-3. Boundary-aware Segmentation Experiment

실험 배경

앞선 EDA 분석을 통해, 본 데이터셋은 단순한 다중 클래스 분리 문제가 아니라 구조적으로 인접·중첩된 뼈 클래스들로 인해 경계 영역에서 오류가 빈번히 발생하는 segmentation task임을 확인하였다. 특히 carpal bone 영역에서는 경계 밀집도로 인해 class bleed-through 현상이 반복적으로 관찰되었다.

이러한 특성을 고려할 때, 단순히 backbone이나 모델 규모를 키우는 접근보다는 **경계 정보를 어떻게 모델이 인식하고 활용하는지**가 성능 개선의 핵심일 수 있다고 판단하였다. 이에 따라 본 실험에서는 boundary 정보를 학습 과정에 명시적으로 포함시키는 다양한 구조적 접근을 단계적으로 탐색하였다.

Baseline 설정

Boundary 실험에 앞서 비교 기준이 될 baseline 모델을 설정하였다.

하이퍼 파라미터	값
Model	U-Net++
Encoder	ResNet50
Pretrained Weight	ImageNet
Augmentation	Resize(512x512)
Loss	BCE
Learning Rate	0.0001 (Scheduler X)
Optimizer	Adam
Data split	Fold 0
Random Seed	21
Threshold	0.5
Batch Size	8
Num Epochs	60
Val Every	2
Num Patience	-

Backbone 실험

또, backbone 구조 차이에 따른 기본 성능을 비교하였다.

Encoder	Val Dice	LB Score
ResNet50	0.9527	0.9389
ResNeXt50_32×4d	0.9553	0.9426

ResNeXt50_32×4d는 group convolution 기반의 구조적 다양성으로 인해 ResNet50 대비 소폭이지만 일관된 성능 향상을 보였다. 다만 연산량 증가로 인해 학습 시간이 증가하였으며, 이후 실험에서는 backbone 구조를 ResNeXt50_32×4d로 고정된 상태에서 추가 실험을 진행하였다.

Pretrained Weight 효과 분석

Backbone 구조를 ResNeXt50_32×4d로 고정한 뒤, encoder 사전학습 여부에 따른 성능 차이를 분석하였다. 이는 이후 boundary 구조 실험에서 성능 변화를 해석할 때, 구조적 변화와 사전학습 효과를 분리하기 위함이다.

Pretrained Weight	Val Dice	LB Score
ImageNet	0.9553	0.9426
scratch	0.9319	-

Pretrained weight를 사용하지 않은 경우 validation Dice가 크게 감소하였으며, 학습 수렴 속도 또한 현저히 느려졌다. 이를 통해 본 데이터셋에서는 encoder 사전학습이 성능의 향상을 결정하는 중요한 요소임을 확인하였다. 이에 따라 이후 모든 boundary 실험에서는 encoder를 ImageNet pretrained로 고정하였다.

Boundary 구조 설계 개요

Boundary 실험은 경계 정보를 segmentation에 통합하는 방식에 따라 세 단계로 설계되었다. 각 구조는 이전 실험에서 관찰된 한계를 보완하는 방향으로 확장되었다.

Dual-Head Boundary-Segmentation 구조

Dual-Head 구조는 하나의 encoder를 공유한 뒤, segmentation과 boundary를 각각 예측하는 두 개의 decoder head를 분리하여 학습하는 방식이다. 본 구조의 목적은 모델이 경계 정보를 segmentation과 동등한 task로 명시적으로 학습하도록 유도하는 것이었다.



본 구조의 목적은 모델이 경계 정보를 segmentation과 동등한 task로 명시적으로 학습하도록 유도하는 것이었다. 실험 결과, 두 task 간 난이도 차이로 인해 gradient 간섭이 발생하였고, 60 epoch 기준에서는 충분한 수렴에 도달하지 못하였다. 성능 또한 baseline 대비 낮은 값을 기록하여, 본 구조는 구조적 가능성 탐색 단계에서 종료하였다.

BASNet-like Boundary-aware 구조


Dual-Head 구조의 한계를 바탕으로, boundary 정보를 segmentation 전체에 직접 주입하기보다는 **refinement 단계에서 선택적으로 활용하는 구조**가 필요하다고 판단하였다. 이에 따라 semantic stream과 boundary stream을 분리한 BASNet-like 구조를 설계하였다.



이 구조에서는 boundary 정보가 segmentation mask 전체를 재예측하지 않고, 경계 주변 영역에 한해서만 보정 역할을 수행하도록 제한하였다.

BASNet-like+ Refinement + Transformer 구조

BASNet-like 구조를 기반으로, refinement 단계에 transformer 기반 중재 모듈을 추가한 구조도 실험하였다. 해당 구조는 boundary confidence를 기반으로 class 간 관계를 global context에서 조정하고자 한 시도였다.



이는 refinement 대상이 국소 영역임에도 불구하고, global context modeling에 최적화된 transformer 구조를 적용함으로써 모델 구조와 문제 특성 간의 정합성이 충분히 확보되지 않았기 때문에 해석할 수 있다.

Boundary 구조 실험 결과 요약

Boundary 방식	Val Dice	LB Score
baseline	0.9553	0.9426
Dual-Head	0.8632	0.8509
BASNet-like + Ref	0.9548	0.9413
BASNet-like + Ref + Trans	0.9281	-
BASNet-like + Ref (120 epoch)	0.9639	0.9475

Boundary-aware 구조의 실제 효과를 확인하기 위해 baseline(60 epoch)과 충분히 수렴한 BASNet-like + refinement(120 epoch) 모델을 비교하였다.

정량적 Dice score 차이는 크지 않았으나, boundary-aware 모델은 경계 부근에서 class 침범이 감소하는 경향을 보였다. 이는 Dice metric이 면적 기반 지표로서 경계 위치의 미세한 변화에는 상대적으로 둔감하기 때문이며, boundary-aware 구조의 효과가 정량 지표에 충분히 반영되지 않았을 가능성을 시사한다.

Loss 조합 실험 (BASNet-like + Refinement)

Boundary 구조 중 가장 안정적인 성능을 보였고, 120epoch으로 포텐셜을 확인하여 BASNet-like + refinement 구조를 기준으로 loss 조합 실험을 수행하였다.

Loss	Val Dice	LB Score
BCE + boundary	0.9548	0.9413
BCE + Dice + boundary	0.9663	0.9508

BCE + Dice + Jaccard + boundary	0.9654	0.9496
------------------------------------	--------	--------

Boundary loss가 추가되어 있는 상태에서 loss를 추가하여 실험해봤을 때 BCE + Dice + boundary가 가장 성능이 좋아 loss를 해당 조합으로 고정하였다.

최종 모델 성능 확인

최종 모델 성능을 확인하기 위해 하이퍼 파라미터를 설정했다.

하이퍼 파라미터	값
Model	U-Net++
Encoder	ResNeXt50_32x4d
Pretrained Weight	ImageNet
Augmentation	Resize(2048x2048)
Loss	BCE + Dice + boundary
Learning Rate	0.0001
Optimizer	Adam
Data split	Fold 0
Random Seed	21
Threshold	0.5
Batch Size	1
Num Epochs	150
Val Every	1
Num Patience	15
Scheduler	ReduceLROnPlateau
Augmentation	UperNet과 동일

최종 모델 성능을 검증하는 과정에서 augmentation, scheduler, batch size 조정을 동시에 적용하여 실험 변수를 충분히 통제하지 못한 한계가 존재하였다. 특히 고해상도 입력을 적용하며 batch size를 1로 조정된 실험에서는 validation Dice가 0.8778까지 급격히 감소하였고, 이는 학습이 정상적으로 수렴되지 않았음을 시사한다. 해당 실험은 최종 앙상블 구성에는 포함하지 않았다.

Boundary 실험 종합 정리

본 boundary 관련 실험의 목적은 단순한 성능 향상보다는, 본 데이터셋에서 segmentation 성능을 제한하는 요인을 구조적으로 이해하는 데 있었다. 실험 결과, 사전학습된 encoder는 성능의 하한선을 결정하는 핵심 요소임을 확인하였으며, boundary 정보는 Dice metric 자체를 크게 향상시키기보다는 경계 부근의 오류 패턴을 변화시키는 역할에 가까웠다. 이러한 특성은 Dice와 같은 면적 기반 지표의 한계를 보여주는 동시에, 향후 보다 강력한 backbone 또는 boundary-sensitive metric(e.g. contour-based or surface distance metric)과 결합할 경우, boundary 정보가 실질적인 성능 개선으로 이어질 가능성을 시사한다.

1-4-3-4. Swin-unet

상기 내용과 같이 인접·중첩된 뼈 경계에서는 국소적인 픽셀 정보만으로는 정확한 분류가 어려워, 전체적인 구조와 문맥 정보를 함께 고려하는 것이 중요하다고 판단하였다. 이에 따라 Transformer의 전역 정보 학습 능력과 U-Net의 지역적 특징 및 경계 복원 능력을 동시에 활용할 수 있는 swin-unet 모델을 선택하였다. GPU 메모리 제약으로 batch size를 크게 설정할 수 없어, Gradient Accumulation(GA)을 사용하여 더 큰 batch size로 학습한 것과 동일한 효과를 얻고자 하였다. 이를 통해 학습 안정성이 개선되었으며, Early Stopping을 적용하여 과적합을 방지하였다. 또한, 학습 효율을 높이기 위해 Automatic Mixed Precision(AMP)를 적용하였다. 최종 모델은 1024×1024 해상도에 batch size 4, Gradient Accumulation(GA) 2, contrast, rotate 증강을 적용하였다. 모델의 특성 상 학습시간이 오래 걸리고 GPU의 제약이 있어 엄밀한 경우의 수를 실험하지 못했음을 밝히며 이를 결정하기 위한 실험 과정은 다음과 같다.

Loss에 대한 영향을 파악하기 위해 window size를 8, 기존 Bice loss에 Dice loss를 포함하여 실험하였다.

Loss(1024×1024)	Batch Size	Val Dice	Val loss
BCE only	4	0.9566	0.0008
BCE + Dice(1:1)	4	0.9608	0.0340
BCE + Dice(3:7)	4	-	-

BCE와 Dice loss를 1대1로 하였을 때 성능 향상을 보았지만, Dice loss의 비율을 키웠을 때 정상적인 형태의 학습이 되지 않아(loss가 점점 수렴하지 않았음.) 실험을 중단하였다. 따라서 loss를 BCE와 Dice를 1대1로 고정하여 실험하기로 하였다.

이 과정에서 1024 해상도에서의 실험은 학습 시간이 17시간 이상 소요되어 다양한 조합을 실험하기 어려웠다. 이에 따라 다음과 같은 전략을 채택하였다. 낮은 해상도에서 실험한 후 해당 설정이 고해상도에서 유효할 것이라는 가정 하에 1024 해상도에 재적용 하고자 하였다.

512의 해상도로 gradient accumulation의 성능을 확인하기 위한 실험을 하였다. Gradient accumulation은 GPU가 제한된 상황에서 batch size를 크게 하는 것처럼 계산을 해 학습의 안정성을 추구하기 위해 사용한다. 논문의 batch size는 224인데 반해, GPU의 제약으로 사용할 수 있는 batch size는 4였다. 이에, gradient accumulation을 2를 주어 학습하였다.

	Batch Size	Val Dice	Val loss
Base	4	0.93669	0.0174
GA 2	4	0.95236	0.0185

그 결과 안정된 학습과 val Dice가 향상되는 것을 확인하였다. 따라서 이후 실험은 batch size 4에 gradient Accumulation을 2로 진행하였다. 하지만, 512 해상도 역시 실험 시간이 여전히 오래 걸리기에 224의 해상도로 실험을하기로 결정하였다.

학습 효율을 위해 논문 설정과 동일한 224 해상도, window size 7 환경에서 augmentation 실험을 수행하였다.

Augumentation	Batch Size	Val Dice	Val loss
base	4(2)	0.8919	0.0424
rotate	4(2)	0.9038	0.0277
Rotate, contrast	4(2)	0.9323	0.0257
rotate, contrast, flip	4(2)	0.9272	0.0277

가장 우수한 contrast, rotate의 결과에 해당 augmentation 전략을 고해상도 실험에 재적용하였다.

기존 Swin 설정인 window size 8은 기존 논문의 224 해상도, window 값 7을 기준으로 설정된 값이다. 이는 1024의 고해상도가 되었을 때 상대적으로 작은 receptive field를 가진다고 판단하였다. 따라서 window size를 증가시켜 실험하였다.

Window size	Batch Size	Val Dice	Val loss
base	4(2)	0.9578	0.02889
16	4(2)	0.9596	0.00537

따라서 window size를 16으로 하는 것으로 결정하고 증강을 포함한 최종 모델의 성능은 다음과 같다.

	Batch Size	Val Dice	Val loss
Final swin-unet	4(2)	0.96735	0.01482

1-4-3-5. HRNet-OCR

본 프로젝트에서는 미세한 경계 정보와 클래스 간 공간적 관계를 정밀하게 모델링하는 것이 중요하다고 판단하여, HRNet 기반의 OCR(Object-Contextual Representations) 구조를 선정하였다. HRNet의 고해상도를 유지하며 병렬적으로 다중 해상도 정보를 융합하는 구조와 OCR head를 결합함으로써 문맥 정보와 클래스 간 관계를 명시적으로 활용할 수 있으며, 이를 통해 픽셀 간 경계가 불명확한 영역에서도 보다 정교한 분할 성능을 기대할 수 있다.

또한 팀 내에서 이미 UNet 계열 모델에 대한 다양한 실험이 진행되고 있었으며, HRNet과 UNet의 단순한 결합은 구조적 중복 및 연산 효율 저하를 야기할 가능성이 있다. 이에 따라 모델 다양성 확보 및 구조적 비교 관점에서 HRNet 계열 모델을 독립적으로 선택하여 실험을 진행하는 것이 합리적이라고 판단하였다.

Baseline 설정

Backbone은 HRNetV2-W18, OCR head, 데이터 분할은 Random Split을 적용하였으며, BCE를 기본 손실 함수로 사용하였다. Batch size는 8, Optimizer는 Adam, 초기 LR은 0.0001로 설정하였고, 학습률 스케줄러는 원 논문 설정을 참고하여 PolyLR (power=0.9)를 적용하였다. 입력 이미지 해상도는 1024×1024로 고정하였다.

Validation Split 및 Dice loss 실험

이후 검증 데이터 분할 전략과 손실 함수 조합에 따른 성능 변화를 분석하기 위해, Dice loss를 추가 적용한 경우와 새롭게 정의한 검증 Split(New fold 0)을 포함한 비교 실험을 수행하였다. 실험 결과는 아래 표와 같다.

Split	loss	Val Score	Public LB Score	Best Epoch
Random	BCE	0.9677	0.9642	96
Random	BCE+Dice	0.9709	0.9679	39
Random without noise (363, 487)	BCE+Dice	0.9717	0.9681	81
New Fold 0	BCE	0.9677	0.9659	112
New Fold 0	BCE+Dice	0.9689	0.9671	47

분석 결과 Random split에서는 validation score와 public leaderboard score 간의 차이가 상대적으로 크게 나타났으며, 이는 hard case에 대한 성능 변화가 검증 점수에 충분히 반영되지 못함을 의미한다. 따라서 Random split 기반 validation score는 실험 진행 과정에서 신뢰 가능한 지표로 사용하기 어렵다고 판단하였다. 이에 따라 새로운 검증 분할 전략(New Fold 0)을 도입하였으며, 해당 split에서는

validation score와 leaderboard score 간의 차이가 유의미하게 감소함을 확인하였다. 또한 Dice loss를 도입함으로써 소폭의 성능 향상과 함께 학습 수렴 속도가 증가하는 효과를 확인하였다.

이후 모든 실험에서는 검증 분할을 New Fold 0로 고정하고, 기본 비교 손실 함수로 BCE와 Dice loss를 사용하였다.

Geometric Augmentation 실험

기하학적 데이터 증강(Rotation, Scaling, Translation)을 추가한 경우, validation score와 public leaderboard score가 모두 소폭 향상되었으며, validation-LB 간 gap 또한 감소하였다. 두 지표 간의 gap 또한 감소하였다. 이는 augmentation이 데이터 다양성을 증가시켜 과적합을 완화하는 효과를 제공했기 때문으로 해석된다. 이후 실험에서는 해당 augmentation을 기본 설정으로 고정하였다. Scheduler 실험 또한 병행하여 진행하였으며, 스케줄러 적용 여부에 따른 비교 결과 PolyLR을 적용한 경우의 성능이 소폭 더 높음을 확인하였다.

Aug	Scheduler	Val Score	Public LB Score
X	X	0.9678	0.9671
O	X	0.971	0.9704
O	PolyLR0.9	0.971	0.9706

Focal loss 실험

본 실험의 목적은 Focal loss 도입이 클래스별 오류 양상(FP, FN)에 미치는 영향을 분석하고, 추가적인 loss 설계 또는 가중치 조정의 필요성을 검증하는 데 있었다.

Pisiform과 Trapezoid 클래스는 두 실험 모두 Dice score가 약 0.90~0.91 수준으로 유사하였으나, 오류 구성에서 상이한 양상을 보였다. BCE+Dice 설정에서는 두 클래스 모두 FN이 FP보다 높은 경향을 보였으며, 이는 작고 밀집된 뼈 구조를 모델이 보수적으로 예측하여 실제 뼈 영역을 놓치는 경우가 많았음을 의미한다.

calss	loss	Val Score	precision	recall
Pisiform	BCE+Dice	0.9077	0.9145	0.9009
	+Focal	0.9097	0.9011	0.9184
Trapezoid	BCE+Dice	0.9125	0.9259	0.8994
	+Focal	0.9088	0.9141	0.9035

Focal loss 적용 시 FN이 감소하여 recall은 증가하였으나, 그 반대급부로 FP가 증가하며 precision이 감소하였다. 이는 Focal loss가 hard example에 집중하도록 유도하면서 경계가 불명확한 영역까지 적극적으로 예측하게 된 결과로 해석된다.

다.

Dice score가 0.97을 넘지 못한 클래스(Trapezium, Hamate, Triquetrum, finger-1, Lunate, Capitate, Scaphoid)는 대부분 손목뼈 계열로, Focal loss 적용 시 전반적으로 FP 감소, FN 증가 경향을 보였다. 다만 Hamate 클래스에서는 FN이 감소하는 예외적인 개선 패턴이 확인되었다.

본 실험에서 사용한 Focal loss 설정은 $\gamma = 2$, α 미적용 (None)이었으며, 이는 hard example 집중 효과를 확인하기 위한 초기 탐색 실험이었다. 분석 결과, Focal loss의 효과는 α 설정에 크게 의존하는 것으로 판단되었다.

이에 따라 클래스별 오류 특성을 고려한 Weighted Focal loss를 후속으로 적용하였다. Pisiform, Trapezoid, Hamate에는 $\text{weight}=0.6$, Trapezium, Lunate, Capitate, Scaphoid, Triquetrum에는 $\text{weight}=0.85$ 를 적용하였으며, 그 결과 leaderboard 성능이 소폭 향상되었다.

Loss	Val Score	Public LB Score
BCE+Dice	0.971	0.9706
+Alpha None Focal	0.9711	0.9708
+Alpha Weighted Focal	0.974	0.9709

Scheduler 실험

PolyLR은 전체 epoch 수에 따라 학습률 감소 곡선이 결정되므로, 수렴 특성을 분석하기 위해 최대 epoch을 200으로 설정하고 Early Stopping(patience=20)을 적용하였다. 기존 실험 결과 대부분 60~80 epoch 내에 수렴하는 경향을 보여, 비교 실험에서는 최대 epoch을 80으로 제한한 경우도 함께 평가하였다.

Max Epoch	Val Score	Public LB Score	Best Epoch
200	0.9711	0.9708	60
80	0.9711	0.9701	48

최대 epoch을 80으로 제한한 경우 학습률이 빠르게 감소하여 leaderboard 성능이 소폭 하락하고 validation-leaderboard 간 gap이 증가하였다. 이에 따라 최대 epoch을 200으로 설정한 후 Early Stopping을 적용하는 전략을 최종 선택하였다. 추가적인 scheduler 실험을 진행할 경우 성능 향상의 여지가 있을 수 있으나, 시간 제약을 고려하여 본 설정을 최종 학습 전략으로 채택하였다.

추가 증강 및 Backbone 변경 실험

기존 증강 외에 Flip 및 Contrast 증강을 추가로 실험하였으며, Backbone을 HRNet-W32로 확장하였다. Backbone 크기 증가로 인해 batch size를 줄이고 gradient

accumulation을 적용하였다.

Encoder	Val Score	Public LB Score	bs	Best Epoch
W18	0.9737	0.9702	8	
W18(Flip)	0.974	0.9709	8	60
W32(Flip)	0.9741	0.971	4	48
W32(Flip+Contrast)	0.9745	0.9721	4	

Backbone 확장에서 성능 향상을 확인했고 contrast 증강에서 가장 큰 성능 향상을 확인하였다.


Test-Time Augmentation 실험

최종 best 모델에 대해 Flip 및 Contrast 기반 TTA를 적용하였다. Contrast는 random intensity(0.1~0.3)과 fixed intensity(0.15, 0.3) 설정을 각각 적용한 뒤 평균을 사용하였다.

TTA	Public LB Score
Current Best model	0.9721
Random contrast+flip	0.9728
Fixed contrast+flip	0.9728

2048 해상도 Resize 실험


본 프로젝트에서는 입력 해상도가 미세한 경계 및 소형 구조물 분할 성능에 미치는 영향이 크다고 판단하여, 최종 성능 향상을 목표로 2048 해상도(원본 해상도) 학습 실험을 추가로 수행하였다. 다만 2048 해상도 학습은 메모리 사용량이 급증하여 OOM 문제가 발생하였고, 이에 따라 batch size를 2로 축소하였다. 축소된 batch size로 인한 최적화 불안정을 완화하기 위해 gradient accumulation을 4로 설정하여 유효 batch size를 보완하고자 하였다. 그러나 초기 2048 학습 실험에서는 모델이 정상적으로 수렴하지 못하고 Validation Score가 0으로 붕괴하는 현상이 발생하였다. 또한 일부 실험에서는 학습이 지속되더라도 학습 곡선이 비정상적으로 급격히 변동(spike)하며, 성능이 안정적인 개선 양상을 보이지 않았다.



학습 안정성 원인을 분석하기 위해 학습 곡선을 비교하였다. 노란색 곡선은 1024 best 모델에서 contrast 증강을 적용하지 않은 경우, 빨간색 곡선은 1024 best 모델에서 contrast 증강을 적용한 경우이며, 초록색 곡선은 2048 해상도 실험 결과이다. 노란색 곡선은 비교적 안정적으로 수렴하는 반면,

빨간색 곡선에서는 contrast 증강 도입 이후 일부 구간에서 작은 spike가 확인되었다. 초록색 곡선(2048 실험)은 전반적으로 매우 불안정한 패턴을 보였다.

이를 종합하여, batch size 축소와 contrast 증강이 결합되면서 batch normalization(BN) 통계 추정이 불안정해져 학습이 흔들렸을 가능성이 높다고 판단하였다. 특히 OCR head 내부의 BN 레이어가 소규모 배치 환경에서 불안정성을 유발했을 것으로 가정하고, OCR head의 BN 레이어를 제거한 설정으로 재학습을 수행하였다. 그 결과, 이후 학습에서는 곡선이 안정적으로 수렴하는 양상을 확인할 수 있었다.



2048 해상도로 학습된 모델은 추론 단계에서 기본적으로 TTA를 적용하였다. TTA는 Flip과 Contrast를 사용하였으며, Contrast는 학습 시 설정과 동일한 random intensity(0.1~0.3)를 적용하였다. 최종 성능은 다음과 같다.

Model	Public LB Score
1024 Random contrast+flip TTA	0.9721
2048 Random contrast+flip TTA	0.9753

2048 해상도 학습 + TTA 조합은 1024 대비 유의미한 성능 향상을 보였으며, 최종 성능을 끌어올리는 핵심 요인으로 작용하였다.

1-4-3-6. Ensemble

양상을 실험에서는 soft voting과 hard voting을 비교하여 최종 앙상블 전략을 선정하였다. 후보 모델군은 팀원별 최고 성능 모델인 UNet++, Swin UNet, UPerNet, HRNet-OCR로 구성하였다.

Soft voting vs hard voting

초기 앙상블 비교 실험 당시에는 HRNet-OCR 2048 모델과 UNet++ 모델의 학습이 완료되지 않았기 때문에, Swin UNet, UPerNet, HRNet-OCR 1024 세 모델로 실험을 진행하였다. Soft voting에서는 각 모델의 Public Leaderboard Score를 min-max normalization하여 가중치로 사용하였으며, 성능이 낮은 모델의 기여를 완전히 배제하지 않기 위해 min value를 0.5로 설정하였다.

당시 각 단일 모델의 Public Leaderboard Score는 Swin UNet 0.9575, UPerNet 0.9743, HRNet-OCR 1024 0.9721

이었다. Hard voting과 Soft voting 비교 결과는 다음과 같다.

Ensemble Method	Public LB Score
Hard	0.9738
Soft	0.9745

Hard voting은 오히려 단일 모델 대비 성능이 하락한 반면, Soft voting에서는 성능 향상이 확인되었다. 이에 따라 본 프로젝트의 앙상블 전략은 Soft voting 기반으로 결정하였다.

Ensemble TTA

선정된 Soft voting 앙상블에 대해 TTA를 추가로 적용하였다. TTA는 Flip과 Contrast를 사용하였다. Contrast는 (1) 학습 시와 동일한 random intensity(0.1~0.3) 와 (2) 고정 intensity(0.15, 0.3)를 각각 적용한 뒤, 두 결과를 평균내는 방식으로 진행하였다. 결과는 다음과 같다.

Ensemble Method & TTA	Public LB Score
Soft – Random Contrast	0.9753
Soft – Determined Contrast	0.9752

Random Contrast 설정에서 성능이 소폭 더 높게 나타나, 이후 실험에서는 해당 전략을 채택하였다.

이후 기존에 사용하지 못했던 모델들의 학습이 완료됨에 따라, 앙상블 모델군을 확장하거나 교체하는 실험을 수행하였다. 구체적으로, HRNet-OCR 모델을 1024 버전에서 2048 해상도로 학습된 HRNet-OCR로 교체하였고, 512 해상도로 학습된 UNet++ 모델을 추가하였다. 각 단일 모델의 Public Leaderboard Score는 HRNet-OCR 2048이 0.9753, UNet++ 512가 0.9508이었다.

Models	Public LB Score
Base	0.9753
+HRNet OCR 2048	0.9756
+Unet++ 512	0.9756

표면적으로는 점수 변화가 없었으나, 리더보드 최신화 시점을 확인한 결과 UNet++ 512 모델을 추가하기 전의 성능이 소수점 하위 자리에서 더 높게 기록되었을 가능성이 있다고 판단하였다. 따라서 최종 구성에서는 UNet++ 512 모델을 제외하기로 결정하였다.

Weight 조정 실험(Min value 변경)

Soft voting의 가중치 설계에서, 기존 min-max normalization 설정은 min value=0.5로 성능이 낮은 모델의 영향력을 일정 수준 유지하도록 설계되어 있었다. 그러나 이전

실험 결과를 바탕으로, 저성능 모델의 영향력을 더 낮추는 것이 유리할 수 있다고 판단하여 min value=0.1로 변경한 실험을 수행하였다.

Min Value	Public LB Score
0.5	0.9756
0.1	0.9758

min value를 0.1로 낮춘 경우 Public Leaderboard Score가 소폭 상승하였으며, 이에 따라 min value=0.1 설정을 채택하였다.

Threshold 실험

기존에는 클래스별 예측 확률 threshold를 0.5로 고정하여 제출하였다. 이에 따라 threshold 조정이 성능에 미치는 영향을 확인하기 위해, 가장 성능이 높은 모델의 클래스별 최적 threshold를 적용하는 방식과 모든 모델의 클래스별 최적 threshold를 리더보드 성능 기반 가중치로 평균내는 방식의 두 가지를 계획하였다. 다만 후자는 서버 오류로 인해 제출이 불가능했으며, 전자의 실험 결과는 다음과 같다.

Threshold	Public LB Score
X	0.9758
O	0.9752

클래스별 threshold 적용 시 성능이 오히려 감소하였으며, 이에 따라 최종 제출 전략으로는 Public Leaderboard Score가 상대적으로 높았던 실험 결과를 우선적으로 고려하여, Weight 조정 실험 결과와 HRNet-OCR 2048 갱신 후 제출 결과를 선택하게 되었다. 그 결과, Public Leaderboard 2등, Private Leaderboard 2등이라는 성과를 달성할 수 있었다.

1-5. 팀 회고

본 프로젝트를 진행하며 데이터 전처리 단계에서 일부 label 오류를 충분히 검증하지 못한 채 학습을 진행한 점은 아쉬움으로 남는다. 다만 이전 프로젝트와 달리 스프레드시트를 활용해 모델과 하이퍼 파라미터, 실험 결과를 체계적으로 관리함으로써 실험 흐름을 보다 명확히 파악할 수 있었고, 전반적인 실험 효율도 향상되었다. 또한 프로젝트 초반에 코드 리팩토링을 진행하여 Git 구조를 정비하고, branch 단위로 모델별 실험 코

드를 관리함으로써 협업과 실험 관리 측면에서 안정성을 확보할 수 있었다. 이러한 체계적인 실험 관리와 반복적인 성능 개선 과정을 통해 제한된 자원 환경에서도 모델 성능을 효과적으로 최적화할 수 있었으며, 결과적으로 대회에서 의미 있는 성과(public, private 2등)를 도출할 수 있었다.

그러나, 한정된 서버와 비용 환경을 고려할 때 초기 단계에서 주요 모델군을 사전에 정의하고 공통 설정을 기반으로 역할을 분담해 탐색 실험을 진행한 뒤, 유망한 모델에 대해서만 심층적인 최적화를 수행했다면 실험 자원 활용과 결과 해석 측면에서 더욱 효율적인 프로젝트 운영이 가능했을 것으로 판단된다.

향후에는 간트 차트 등을 활용한 명확한 일정 관리와 함께 우선순위를 분명히 설정하고, 완벽함보다는 전체 완성도를 중시하는 협업 중심의 프로젝트 운영을 지향하고자 한다.

2. 개인회고

2-1. 안태현

지난 프로젝트에서는 실험 관리와 협업 체계가 충분히 정립되지 않아 성과 측면에서도 아쉬움이 컸고, 프로젝트 자체를 의미 있게 이끌어가지 못했다는 아쉬움이 남았다. 반면 이번 프로젝트에서는 체계적인 실험 관리 방법 도입과 변인 통제를 위한 의식적인 노력을 통해 비교적 안정적인 실험 환경을 구축할 수 있었고, 그 결과 좋은 성적을 거둘 수 있었다고 생각한다.

실험 관리 체계 정립과 파이프라인 설정은 초반에는 다소 번거롭고 귀찮게 느껴졌지만, human error를 최소화하기 위한 장치와 팀 차원의 시스템이 결과적으로 얼마나 중요한지 몸소 체감하는 계기가 되었다. 이러한 경험을 실수를 줄이고, 보다 의미 있는 결과를 도출하기 위해 고민하는 습관을 기를 수 있었으며, 스스로 많이 성장했음을 느낀다.

다만 프로젝트 중반부에 코드 설정 실수나 변인 통제를 충분히 고려하지 못한 채 조급하게 실험을 진행하며 허비한 시간들이 있어 아쉬움과 팀원들에 대한 미안함이 남는다. 그럼에도 불구하고 최종적으로 많은 시간을 투자한 모델의 성능이 잘 최적화되어 좋은 결과로 이어진 점은 다행이었고, 개인적으로도 한시름 덜 수 있었다.

아쉬운 점으로는 끝까지 진행하지 못한 class weight boundary loss 실험과 충분히 마무리하지 못한 데이터 정제 실험이 있다. 반복적이고 번거로운 작업이지만, 가장 중요한 요소 중 하나인 데이터 품질을 끝까지 다듬지 못한 점이 특히 아쉽게 느껴진다. 또한 대회 후반부에 validation 데이터의 GT 오류를 확인하면서, 이전 실험 결과들과 완전히 동일한 조건에서 비교·분석하지 못했다는 점이 하나의 오점으로 남았고,

GT 수정 이후 학습 변화에 대한 추가 분석을 진행하지 못한 점도 아쉬움으로 남는다. 잘못된 GT를 포함한 데이터를 기반으로 학습을 진행했다는 점에서 다소 찝찝함이 남았지만, 이를 통해 CV 도메인에서 직접 눈으로 데이터를 확인하고 검증하는 과정의 중요성을 깊이 깨닫게 되었다.

이번 프로젝트를 마무리한 이후에는 사용했던 모델들에 대해 보다 깊이 있는 이론적 학습을 진행하며 부족한 이론적 지식을 보완할 계획이다. 또한 이번 프로젝트에서 얻은 경험과 교훈을 바탕으로, 향후 다른 경진대회나 프로젝트에서도 좋은 성과를 내고 싶다.

2-2. 최정빈

이전 Object Detection 프로젝트를 비교적 낮은 등수로 마무리한 이후, 성과가 나지 않았던 원인을 집중적으로 회고했다. 가장 큰 문제는 시간 부족을 이유로 실험 설계를 허술하게 진행했다는 점이었다. 변인 통제를 통한 비교 실험보다는 경험적으로 효과가 있을 것으로 판단한 방법을 적용하며 성능 향상을 시도했고, 이로 인해 실험 결과에 대한 명확한 해석이 어려웠다.

이번 프로젝트에서는 이러한 한계를 반복하지 않기 위해 처음부터 끝까지 실험 과정을 체계적으로 설계하고, 하나하나 검증해 가며 학습을 진행했다. 각 실험에서 변인을 명확히 통제하며 성능 변화를 확인했고, 그 결과 public / private leaderboard 모두에서 2등이라는 성과를 얻을 수 있었다.

다만 아쉬운 점도 남았다. 예상보다 모델 학습 시간이 길어 CopyPaste augmentation을 적용해 보지 못했고, 프로젝트 후반부에는 시간 부족으로 K-fold ensemble을 진행하지 못했다. 이를 대체하기 위해 전체 데이터를 활용한 학습과 Leaderboard score를 validation 지표로 활용하는 방안을 고려했으나, 대회 막바지에는 제출 횟수 제한으로 인해 충분히 시도하지 못했다. 프로젝트 마무리 단계마다 시간 관리의 중요성을 다시 한번 느끼게 되었다.

그럼에도 불구하고, 위의 한계를 제외하면 초기에 계획했던 실험과 분석을 대부분 수행했다는 점에서 큰 성취감을 느꼈다. 또한 팀원들이 2명씩 서버를 사용하는 상황에서 혼자 서버를 전담하게 되면서 GPU 자원을 최대한 활용하고자 했다. 기존에는 Shell 문법에 익숙하지 않아 실험을 하나씩 실행했지만, 이번에는 Shell 스크립트를 활용해 여러 실험을 연속적으로 실행함으로써 GPU idle 시간을 최소화할 수 있었다. 그 결과 연말·연초 일정이 프로젝트 진행에 미치는 영향을 줄일 수 있었다.

이번 Segmentation 프로젝트를 통해 실험 설계의 중요성과 인프라 활용 능력의 성장을 동시에 경험할 수 있었다. 이러한 경험을 바탕으로 최종 프로젝트에서도 동일한 태도로 임해, 이번 프로젝트와같이 의미 있는 결과를 만들어내고 싶다.

2-3. 박준영

이전 프로젝트에서는 CV Task임에도 불구하고 통계적 수치에만 의존해 데이터를 판단하려 했다. 이러한 접근의 한계를 보완하고자 이번에는 시간을 더 투자하여 모든 원본 이미지를 직접 전수 검사하는 방식을 택했다. 각각의 사진을 하나하나 뜯어본 결과, 숫자로는 파악하기 힘든 데이터의 이상치와 특성들을 발견할 수 있었다. 나아가 모델의 Segmentation 추론 결과 또한 직접 시각적으로 검증하고 피드백하는 과정을 거치며, 정량적 지표가 놓치고 있던 모델의 개선 포인트를 명확히 찾아낼 수 있었다. 결국 중요한 것은 유연한 태도임을 느꼈다. 이번 경험을 토대로, 앞으로는 관성적으로 프로젝트를 진행하기보다 해결해야 할 Task의 본질과 데이터의 특성을 먼저 깊이 있게 고민하려 한다. 수치적 통계가 필요한 곳, 직관적 이해가 필요한 곳 등 각 문제 상황에 가장 적합한 최적의 방법론을 설계하고 적용해 나갈 것이다.

2-4. 윤종욱

이번 프로젝트에서 가장 많이 고민했던 부분은 모델 구조보다도 데이터였다. 초반에는 segmentation 성능을 좌우하는 요소로 small class나 overlap 비율과 같은 직관적인 난이도 기준에 집중했고, 이를 바탕으로 validation split을 구성하려고 시도했다. 그러나 기준이 명확하지 않은 상태에서 난이도를 정의하는 과정에서 주관의 개입될 수 있다는 한계를 느꼈고, 이 방식이 오히려 실험 결과의 신뢰도를 떨어뜨릴 수 있겠다는 생각이 들었다.

이후 방향을 전환하여, 모델 성능이 아닌 데이터 자체의 구조와 메타데이터를 기반으로 split을 재설계하였다. 특히 신장, 성별과 같은 객관적인 정보와 실제 픽셀 분포 간의 관계를 분석한 뒤 이를 validation split에 반영하였고, 그 결과 random split 대비 train-validation gap을 줄일 수 있었다. 이 과정에서 “잘 나누는 것”이 단순히 성능을 높이는 문제가 아니라, 실험 전체의 해석 가능성을 높이는 일이라는 점을 체감했다.

Boundary-aware segmentation 실험 또한 처음에는 성능 향상을 목표로 시작했지만, 결과적으로는 데이터와 metric의 한계를 이해하는 과정에 가까웠다. boundary 정보를 다양한 방식으로 구조에 통합해 보았으나 Dice score 자체는 크게 변하지 않았고, 오히려 Dice metric이 경계 영역의 개선을 충분히 반영하지 못한다는 점이 더 분명하게 드러났다. 성능이 오르지 않았다는 점에서는 아쉬움이 남았지만, “왜 오르지 않았는지”를 설명할 수 있게 되었다는 점에서 의미 있는 실험이었다고 생각한다.

다만 실험 설계 측면에서는 아쉬움도 분명히 남는다. 최종 모델 성능을 확인하는 과정에서 augmentation, scheduler, batch size를 동시에 변경하며 변수를 충분히 통제하지 못했

고, 특히 batch size를 1로 낮춘 실험에서는 학습이 정상적으로 수렴되지 않았다. 실험을 끝까지 깔끔하게 정리하지 못한 채 마무리한 느낌이 남아 개인적으로는 찝찝함이 있다.

그럼에도 불구하고 이번 프로젝트에서 가장 긍정적으로 느낀 점은 팀 협업이었다. 이전 프로젝트에 비해 역할 분담과 실험 공유가 원활했고, 각자의 실험 결과를 바탕으로 의사결정을 빠르게 할 수 있었다. 그 결과 팀 성적 역시 11등에서 2등으로 크게 향상되었고, 혼자였다면 도달하기 어려웠을 결과라고 생각한다.

이번 프로젝트를 통해 모델을 “잘 만드는 것”뿐만 아니라, 데이터를 어떻게 해석하고 실험을 어떻게 설계해야 하는지에 대해 더 깊이 고민하게 되었다. 다음 프로젝트에서는 이번에 남긴 아쉬움을 바탕으로, 변수를 더 엄격하게 통제된 실험과 교차 검증, k-fold ensemble까지 포함한 보다 완성도 높은 실험을 수행해보고 싶다.

2-5. 이승현

이번 프로젝트를 시작하며, 이전 Object Detection 프로젝트에서 기대만큼의 성과를 내지 못했던 원인을 먼저 돌아보았다. 당시에는 팀 내 소통이 충분하지 않았고, 실험 설계 역시 체계적이지 못해 각 실험의 목적과 결과가 명확히 연결되지 않았다고 판단하였다. 이러한 경험을 바탕으로, 이번 프로젝트에서는 팀적인 소통과 체계적 실험 설계를 가장 중요한 주안점으로 두고 진행하고자 하였다.

모델 실험에 앞서 가장 먼저 집중한 부분은 대회 task 자체에 대한 정확한 이해였다. 일반적인 Computer Vision 과제에서는 다양한 입력 환경에 대응하기 위해 강한 데이터 증강을 적용하여 모델의 강건성을 확보하는 것이 중요하다. 그러나 본 과제의 경우 입력 데이터가 항상 손 X-ray 이미지로 고정되어 있다는 점에서, 무조건적인 강한 증강이 반드시 효과적이지 않을 수 있다고 판단하였다. 나아가 PCA 기반 정렬과 같이 입력 분포를 강제로 정규화한다면, 모델의 강건성 요구 자체가 줄어들 수 있다는 가설도 고려하였다. 다만 해당 접근은 구현과 검증에 많은 자원이 필요했고, 팀 내 다른 실험에서 이미 충분한 성능이 확인되고 있었기 때문에, 한정된 자원을 고려하여 모델 선정과 튜닝에 집중하는 것이 합리적이라고 판단하였다.

프로젝트를 진행하며 핵심적인 문제 중 하나로 인식한 것은 하나의 픽셀이 여러 클래스에 동시에 속할 수 있는 overlap 문제였다. 초기에는 segmentation 모델이 클래스 수만큼의 output channel을 가지므로 구조적으로 overlap 자체는 큰 문제가 아니며, 평가 지표인 Dice score에서 분모가 증가하는 현상이 더 중요하다고 판단하였다. 이에 따라 단순히 threshold 조정이 핵심 해결책이 될 것이라고 생각하였다. 그러나 팀 논의와 validation 결과 분석을 거치며 해당 인식은 수정되었다. 실제로 모델은 각 클래스의 feature map을 완전히 독립적으로 생성하지 않기 때문에, 겹쳐진 영역에서 어떤

클래스에 픽셀이 할당되는지는 여전히 중요한 문제였다. 또한 threshold는 Dice 계산에 직접적인 영향을 미치므로, 단일 threshold를 일괄 적용하기보다는 모델별·클래스별 validation 기반 분석이 필요하다는 점을 인식하게 되었다.

이와 같이 자신의 의견을 제시하고, 팀 내 논의를 통해 지속적으로 수정해 나가는 과정을 거치며 문제를 보다 명확하게 인식해 가는 경험을 할 수 있었다. 단순히 개인의 가설을 유지하는 것이 아니라, 타인의 관점과 실험 결과를 바탕으로 판단을 조정하는 과정이 문제 이해의 깊이를 크게 넓혀준다는 점을 체감하였다.

한편, 시도해 보고 싶었던 실험의 경우의 수와 적용해 보고자 했던 기법은 많았으나, 제한된 시간과 GPU 자원으로 인해 모든 아이디어를 실험으로 검증하지는 못했다. 이로 인해 이상적인 실험 설계와 현실적인 제약 사이의 간극을 직접 경험하게 되었고, 제약된 환경에서는 모든 실험을 시도하기보다 우선순위를 명확히 설정하고, 가장 효과가 클 것으로 판단되는 실험에 집중하는 것이 중요하다는 점을 깨닫는 계기가 되었다.

3. Appendix

3-1. A. Class-wise Overlap Statistics

각 클래스별 평균 픽셀 수, overlap 픽셀 수 및 overlap ratio를 정량적으로 분석한 결과를 본 부록에 제시한다. 해당 통계는 본문에서 관찰된 overlap 특성이 특정 클래스, 특히 carpal bone 영역에서 집중적으로 나타난다는 점을 정량적으로 뒷받침한다.

class	mean_pixels	mean_overlap_pixels	overlap_ratio	pixel_minus_overlap
finger-1	8084.88	172.96	0.0213	7911.92
finger-2	16539.68	324.91	0.0196	16214.77
finger-3	27070.92	420.99	0.0155	26649.92
finger-4	5099.96	4.87	0.0009	5095.08
finger-5	9897.48	115.50	0.0116	9781.97
finger-6	21704.65	180.14	0.0083	21524.50
finger-7	35852.0	1446.16	0.0403	34405.83
finger-8	5906.25	3.66	0.0006	5902.58
finger-9	12591.96	113.09	0.0089	12478.87
finger-10	24203.4	171.14	0.0070	24032.31
finger-11	32778.4	1309.69	0.0399	31468.7

	7			8
finger-12	5833.02	4.50	0.0007	5828.52
finger-13	11127.62	98.59	0.0088	11029.03
finger-14	20488.7	128.36	0.0062	20360.43
finger-15	24501.77	1920.97	0.0784	22580.79
finger-16	4032.39	4.24	0.0010	4028.15
finger-17	6458.56	107.62	0.0166	6350.93
finger-18	14395.16	156.67	0.0108	14238.49
finger-19	24835.0	2243.69	0.0903	22591.36
Trapezium	9632.51	3663.99	0.3803	5968.51
Trapezoid	5937.82	3051.39	0.5138	2886.42
Capitate	15831.11	4657.37	0.2941	11173.74
Hamate	11509.22	3165.33	0.2750	8343.89
Scaphoid	10747.36	3305.65	0.3075	7441.71
Lunate	8521.09	2687.06	0.3153	5834.02
Triquetrum	7360.22	3907.04	0.5308	3453.18
Pisiform	4427.01	3608.03	0.8150	818.97
Radius	75942.5	2545.96	0.0335	73396.58
Ulna	40044.31	191.65	0.0047	39852.65